

같은 수학, 다른 용어:

AIFFEL GoingDeeper NLP 커리큘럼(Seq2seq부터 Transformer 번역까지)에 쓰이는 용어에 대한 통신공학적 재해석

김관호 (Kim, Kwan-ho)

AIFFEL Research 온라인 18기 — MainQuest 3

2026년 7월 28일

국문 초록

본 연구는 AIFFEL GoingDeeper NLP 커리큘럼의 관련 프로젝트 노드 4개 — Seq2seq 번역기, Transformer 번역기, BERT 사전학습, HuggingFace 커스텀 프로젝트 — 에서 사용되는 용어를 통신공학의 기존 용어 체계와 대조한다. 통신공학을 전공한 배경을 가진 저자가 GoingDeeper NLP 과정을 이수하며 관찰한 바에 따르면, 딥러닝에서 새로운 개념으로 소개되는 여러 핵심 용어들은 실제로는 고전적인 정보이론·통신이론에서 이미 정식화된 수학적 대상을 다른 이름으로 재명명한 것에 해당한다. 본 논문은 이러한 관찰을 체계적인 용어 대조 분석으로 발전시켜, 용어쌍을 완전동일(exact)·수학적 대응(mathematical)·개념적/구조적 대응(conceptual)의 세 층위로 분류한다. 동시에, 표면적으로는 매력적이지만 실제로는 성립하지 않는 유추(예: 'beam search' 디코딩과 RF 'beamforming'은 단어만 같을 뿐 무관하다)도 함께 제시하여 유추의 오남용을 경계한다. 나아가 본 논문은 이 용어적 단절을 역사적으로 조명한다. 1955년 다탈머스 제안서에 Claude Shannon이 실제 서명자로 참여했다는 문헌상 사실과, John McCarthy가 Norbert Wiener의 '사이버네틱스'와 구분짓기 위해 '인공지능'이라는 이름을 선택했다는 AI 역사학자들의 서술을 검토한다. 이 분석을 바탕으로, 통신공학 배경을 가진 학습자를 위한 '가교 용어집(bridge glossary)'을 GoingDeeper NLP 온보딩 자료로 제안하며, 학습자의 사전 지식을 고려한 커리큘럼 설계가 엄밀성을 해치지 않으면서도 중복 학습 시간을 줄일 수 있음을 논증한다.

주제어: Shannon 정보이론, Transformer, 용어 대조 분석, 다탈머스 회의, 교차엔트로피, AIFFEL GoingDeeper 커리큘럼

I. 서론

1.1 연구의 배경 및 동기

AIFFEEL GoingDeeper NLP 트랙은 9개의 프로젝트 노드로 구성되며, 이 중 4개는 신경망 기계번역과 언어모델링에서 하나의 일관된 흐름을 이룬다: Seq2seq 순환신경망 구조로 번역기를 만들고, 동일한 번역기를 Transformer로 다시 구현하며, BERT 방식의 마스크 언어모델을 사전학습하고, 마지막으로 HuggingFace Transformers 라이브러리 위에 커스텀 파이프라인을 구성하는 것이다. 이 흐름을 완수하는 것은 결코 쉽지 않다. 각 노드는 수학적 명세로부터 아키텍처를 충실하게 구현하고, 실제 코퍼스로 학습시키며, 명시된 정량 지표에 대해 평가할 것을 요구한다.

저자는 이 흐름에 다소 특이한 관점에서 접근하였다. 컴퓨터공학이 아니라 통신·신호처리공학을 전공한 배경이다. 그 관점에서 보면 무시하기 어려운 패턴이 반복적으로 나타났다. 엔트로피 기반 손실함수, 가중치 부여 메커니즘으로서의 어텐션, 위치 인코딩, 순차적인 그리디/빔 디코딩 등 커리큘럼이 딥러닝의 고유한 개념으로 소개하는 것들이, 수십 년 전 통신·정보이론에서 이미 정식화된 대상과 반복적으로, 때로는 정확히 일치하였다. 통신공학자에게 익숙한 비유로 이 문제를 정확히 표현할 수 있다: 이미 5G 네트워크의 신호처리 수학을 습득한 엔지니어가, 그 수학이 새로운 이름을 달고 다른 커리큘럼에서 다시 등장했다는 이유만으로 처음부터 다시 배워야 할 필요는 없다. 그런데 GoingDeeper NLP 커리큘럼의 여러 대목은, 이미 통신공학 어휘를 갖춘 학습자에게 사실상 이것을 요구하고 있었다.

이 관찰은 '딥러닝은 통신공학에 불과하다'는 주장이 아니다. 본 논문의 목적은 Transformer나 GoingDeeper 커리큘럼의 독창성을 부정하는 것이 아니라, 어느 부분이 실제로 선행 연구를 중복하고 있고 어느 부분이 그렇지 않은지를 — 유추가 성립하지 않는 지점까지 포함하여 — 명시적으로 밝힘으로써, 인접 배경을 가진 학습자에게 커리큘럼이 더 효율적으로 전달될 수 있도록 하는 것이다.

1.2 연구 질문

본 논문은 세 가지 질문을 다룬다. 첫째, Seq2seq·Transformer·BERT·HuggingFace 프로젝트 노드에서 사용되는 핵심 용어들은 통신공학의 기존 개념과 어느 정도로 대응하는가 — 완전히 동일한가, 수학적으로 대응하는가, 혹은 개념적으로만 유사한가? 둘째, 이 대응관계는 어디에서 무너지며, 유추를 과도하게 확장할 때

어떤 위험이 따르는가? 셋째, 이러한 대응관계가 확인된다면, 통신공학 배경을 가진 학습자의 중복 학습을 줄이면서도 그렇지 않은 학습자의 학습 엄밀성은 악화시키지 않는 커리큘럼 구성 방식은 무엇인가?

1.3 연구 범위와 방법

본 논문의 분석은 단독 저자에 의한 탐색적 용어 검토이며, 통제된 실험이나 형식적인 복잡도 이론적 증명이 아니다. III장은 검토한 용어 코퍼스, 참고한 1차 문헌, 분류 프로토콜을 문서화하는데, 이는 AIFEL 논문 작성 가이드가 요구하는 '실험 조건'에 상응한다. IV장은 이 용어적 분리를 역사적으로 조명하며, V장은 일반 대중에게 논지를 전달하기 위해 저자가 제작한 인터랙티브 시각화 프로토타입을 소개한다. VI장은 커리큘럼에 대한 함의를 논의하고, VII장은 본 방법론의 한계를 명시적으로 밝힌다.

II. 이론적 배경

2.1 GoingDeeper NLP 커리큘럼: 관련 프로젝트 노드 4개

아래 표 1은 본 논문이 다루는 4개 프로젝트 노드를 GoingDeeper NLP 트랙 전체 안에 위치시킨다. 커리큘럼에 명시된 각 노드는 (i) 목표 아키텍처의 충실한 구현, (ii) 지정된 코퍼스에 대한 학습, (iii) 명시적 지표(예: 번역 품질의 BLEU 점수, 언어모델링의 perplexity/다운스트림 정확도)에 대한 정량 평가, 그리고 결과에 대한 서술형 분석을 요구한다.

GoingDeeper NLP 노드	커리큘럼상 일반 목표
Seq2seq 번역기	어텐션을 포함한 RNN/LSTM 인코더-디코더 구현; 병렬 코퍼스로 학습; 번역 품질을 정량적으로 평가.
Transformer 번역기	Vaswani et al.(2017)의 Transformer 인코더-디코더 구현; 동일 또는 유사 코퍼스로 학습; Seq2seq 베이스라인과 번역 품질·어텐션 양상을 비교.
BERT 사전학습 모델	BERT 방식의 마스크 언어모델(Devlin et al., 2019) 구현 또는 파인튜닝; 사전학습 목표와, 선택적으로 다운스트림 과제에 대해 평가.
HuggingFace 커스텀 프로젝트	HuggingFace Transformers 라이브러리(Wolf et al., 2020)를 이용한 종단간 NLP 파이프라인 구성; 사전학습 모델을 커스텀 과제/데이터셋에 적용.

표 1. 본 논문이 사례로 다루는 GoingDeeper NLP 프로젝트 노드 4개.

2.2 새년의 수학적 통신이론

Claude Shannon의 1948년 논문 「A Mathematical Theory of Communication」(Shannon, 1948; Shannon & Weaver, 1949)은 두 가지 질문을 정식화했다: 메시지의 정보량을 어떻게 측정하는가, 그리고 잡음이 있는 채널이 신뢰성 있게 전달할 수 있는 정보량은 얼마인가. Shannon은 심볼 확률 $p(x)$ 를 갖는 정보원의 엔트로피를 $H(p) = -\sum p(x) \log_2 p(x)$ 로, 대역폭 B 와 신호대잡음비 S/N 을 갖는 채널의 용량을 $C = B \log_2(1 + S/N)$ 로 정의하였다. 그림 1은 Shannon의 정형화된 5단계 통신 모델과, GoingDeeper NLP 커리큘럼에서 사용되는 Transformer 기반 번역 파이프라인을 나란히 배치하여 두 구조가 공유하는 거친 수준의 구조를 보여준다.




그림 1. 새년의 통신 모델(상단)과 GoingDeeper NLP에서 사용되는 Transformer 기반 번역 파이프라인(하단)을 나란히 배치하여 '정보원 → 변환 → 목적지' 구조의 공유를 보인다. 여기서의 대응은 구조적 대응이며, 어느 부분이 수학적으로도 대응하는지는 III장에서 검토한다.

2.3 크로스엔트로피: 유일하게 정확히 성립하는 대응

본 논문이 비교하는 용어들 중, 새년 엔트로피와 GoingDeeper NLP 커리큘럼의 거의 모든 모델 학습에 쓰이는 크로스엔트로피 손실함수의 관계는 단순한 유추가 아니라 정확한 수학적 동일성을 보이는 가장 명확한 사례이다. 그림 2에서 보듯, 정답 분포 P 와 예측 분포 Q 사이의 크로스엔트로피 $L(P, Q) = -\sum P(x) \log_2 Q(x)$ 는 $L(P, Q) = H(P) + D_{KL}(P \parallel Q)$ 로 분해된다. 표준적인 지도학습-언어모델링에서와 같이 P 가 원-핫(one-hot) 라벨일 때 $H(P) = 0$ 이므로, 크로스엔트로피 손실을 최소화하는 것은 모델의 예측 분포에서 정답 분포로의 KL-발산(Kullback-Leibler divergence)을 최소화하는 것과 수학적으로 완전히 동일하다(Goodfellow,

Bengio, & Courville, 2016, 3장; Cover & Thomas, 2006). 이는 통신공학의 비유를 머신러닝에 억지로 씌운 것이 아니라, 서로 다른 과목명 아래 같은 유도 과정을 거쳐 가르쳐지는 동일한 대상이다.

새넨 엔트로피 (1948)

$$H(p) = -\sum_x p(x) \log_2 p(x)$$

채널을 통과하는 하나의 확률분포가 갖는 불확실성을 측정한다.

크로스엔트로피 손실함수 (표준 머신러닝)

$$L(P, Q) = -\sum_x P(x) \log_2 Q(x)$$

정답 분포 P와 모델의 예측 분포 Q 사이의 차이(발산)를 측정한다.

참고: $L(P, Q) = H(P) + D_{KL}(P||Q)$. 정답이 원-핫(one-hot) 분포일 때 $H(P) = 0$ 이므로 $L(P, Q) = D_{KL}(P||Q)$ 가 되어, 크로스엔트로피 손실을 최소화하는 것은 KL-발산을 최소화하는 것과 수학적으로 동일하다 (Goodfellow, Bengio & Courville, 2016, 3장). 이는 비유가 아니라 정확한 수학적 관계이다.

그림 2. 새넨 엔트로피와 표준 머신러닝 크로스엔트로피 손실함수는 동일한 함수형을 가진다. 원-핫 라벨 분포 하에서 하나를 최소화하는 것은 다른 하나의 KL-발산을 최소화하는 것과 수학적으로 동치이다.

III. 용어 대조 분석

3.1 방법: 코퍼스와 분류 프로토콜

일화적 비교를 넘어서기 위해 본 논문은 표 2에 요약된, 명시적으로 공개된 프로토콜을 채택한다. 저자는 표 1의 4개 GoingDeeper NLP 노드에 대한 1차 명세 문서와, Shannon(1948), Vaswani et al.(2017), Devlin et al.(2019), 그리고 표준 통신공학 문헌을 검토하여 두 용어체계에서 반복적으로 나타나는 용어쌍 후보를 수동으로 추출하였다. 각 후보 쌍은 다음 세 층위 중 하나로 분류되었다: (1) 완전동일(Exact) — 용어와 그 기저의 수학적 대상이 두 분야에서 문자 그대로 동일함; (2) 수학적 대응(Mathematical) — 용어는 다르지만, 인용 가능한 문헌에 의해 동일한 연산이라는 것이 형식적으로 증명됨; (3) 개념적 대응(Conceptual) — 진정한 구조적·기능적 유사성이 있지만 동일한 수학적 연산으로 도출되지는 않으며, 증명이 아니라 교육적 발견법(heuristic)으로 취급되어야 함.

분석 조건	설명
검토한 1차 문헌	Shannon(1948); Shannon & Weaver(1949); Vaswani et al.(2017); Sutskever, Vinyals, & Le(2014); Devlin et al.(2019); Wolf et al.(2020); Cover & Thomas(2006); GoingDeeper NLP 노드 명세 4건(표 1)

분석 조건	설명
식별된 후보 용어쌍 수	45개 (저자의 수동 추출, 1회차)
인용 가능한 1차 문헌 대조 후 채택된 용어쌍	18개 (표 3, 총위 1~3)
허위 동족어(false cognate)로 제외된 용어쌍	4개 (표 4)
분류자(coder)	단독 저자. 2차 분류자에 의한 상호검증(inter-rater reliability)은 수행되지 않음 (VII장 한계 참조).
분류 기준	총위1 완전동일 / 총위2 수학적 대응 / 총위3 개념적 대응 (3.1절에서 정의)

표 2. III장 용어 대조 분석에 사용된 분석 코퍼스 및 분류 프로토콜.

3.2 결과: 대응관계의 세 총위

표 3은 채택된 18개 용어쌍을 총위별로 나열한다. 6개(33%)는 완전동일 대응을 보이고, 7개(39%)는 인용 가능한 근거를 통해 도출 가능한 수학적 대응을 다른 이름 아래 보이며, 5개(28%)는 구조적·기능적 유사성만을 보여 본 논문에서는 증거가 아니라 교육적 발견법으로 취급한다. 이 비율은 45개 용어로 구성된 작업 목록에 대한 저자 단독의 1회차 분류를 기술하는 것이며, 검증된 모집단 추정치가 아님을 유의해야 한다.

총위 1 — 완전동일 대응:

AI/NLP 용어	통신공학 개념	총위	근거/출처
엔트로피 (Entropy)	새넨 엔트로피 $H(p)$	완전동일	Shannon (1948)
크로스엔트로피 손실함수	크로스엔트로피 / 상대엔트로피	완전동일	Cover & Thomas (2006); Goodfellow et al. (2016)
KL-발산 (증류·VAE 등에 사용)	Kullback-Leibler divergence	완전동일	Cover & Thomas (2006)
소프트맥스 정규화	볼츠만/깁스 분포의 분배함수	완전동일	Goodfellow et al. (2016), 6장

총위 2 — 다른 이름 아래의 수학적 대응:

AI/NLP 용어	통신공학 개념	총위	근거/출처
어텐션 가중치 (Q·K 유사도)	커널 가중 상관 / 정합필터	수학적 대응	Tsai, Bai, Yamada, Morency, & Salakhutdinov (2019)

AI/NLP 용어	통신공학 개념	총위	근거/출처
사인파 위치 인코딩	푸리에 기저 주파수 인코딩	수학적 대응	Vaswani et al. (2017), 3.5절
드롭아웃 정규화	곱셈적 잡음 주입 / 소거채널 유사구조	수학적 대응	Wager, Wang, & Liang (2013)
잔차(residual) 연결	신호와 보정항의 선형 중첩	수학적 대응	He, Zhang, Ren, & Sun (2016)

총위 3 — 개념적/구조적 대응 (교육적 발견법에 한정):

AI/NLP 용어	통신공학 개념	총위	근거/출처
토큰라이저 / 어휘사전	소스코딩 코드북(codebook)	개념적 대응	발견법; 도출된 동일성 아님
컨텍스트 윈도우 길이	채널 용량 (대역폭 $\times\log(1+\text{SNR})$)	개념적 대응	둘 다 유한한 자원이지만 서로 무관한 제약에서 유도됨
멀티헤드 어텐션	다이버시티 결합 (예: MRC 최대비결합)	개념적 대응	둘 다 여러 개의 가중된 병렬 추정치를 결합함
임베딩 벡터 공간	IQ 신호공간 / 별자리도(constellation)	개념적 대응	둘 다 이산 심볼을 연속 벡터공간에 대응시킴
자기회귀적 디코딩 루프	피드백 / 재전송 루프	개념적 대응	둘 다 반복적이지만 재시도 로직의 메커니즘은 근본적으로 다름

표 3. 대응 총위별로 분류된 채택 용어쌍 18개 (총위 정의는 3.1절, 제외된 용어쌍은 3.4절 참조).

3.3 GoingDeeper NLP 4개 노드에 대한 사례 분석

Seq2seq 노드에서는 인코더-디코더 RNN을 Shannon의 정보원-인코더-채널-디코더-목적지 파이프라인(그림 1)에 직접 대응시켜 읽을 수 있다. '컨텍스트 벡터' 병목은 대역제한 채널의 역할을 하며, 장문에서 나타나는 번역 품질 저하는 고정 대역폭 채널이 갖는 용량 한계를 그대로 반영한다.

Transformer 노드에서, 본 논문의 코퍼스 중 가장 강력하고 방어 가능한 수학적 대응은 어텐션 메커니즘과 커널 가중 상관 사이의 대응이다. Tsai et al.(2019)은 Vaswani et al.(2017)의 스케일드 내적 어텐션이 Nadaraya-Watson 커널 회귀로 표현될 수 있음을 형식적으로 보였는데, 이는 수신 신호를 참조 템플릿 बैं크와 상관(correlation)시키는 정합필터와 구조적으로 동일한 연산이다. 기하적으로 증가하는 파장의 사인파로 구성된 위치 인코딩은, OFDM 파일럿 신호에서 위치·타이밍을 인코딩하는 데 사용되는 것과 정확히 같은 종류의 푸리에형 기저를 직접 응용한 것이다.

BERT 노드에서, 마스크 언어모델 사전학습은 채널코딩 과제로 읽을 수 있다. 입력 토큰 중 일부가 의도적으로 손상되며(이진 소거 채널과 유사), 모델은 원래 시퀀스를 복원하도록 학습된다 — 사전학습 목표는 이 특정하고 제한된 의미에서, 비트가 아니라 텍스트에 대해 수행되는 오류정정 과제이다.

HuggingFace 노드에서는 대부분의 용어가 수학적이라기보다 개념적이다. 토큰나이저, 사전학습된 인코더, 과제 헤드로부터 파이프라인을 구성하는 것은 코드북·트랜시버·응용계층 프로토콜로부터 모듈형 통신 시스템을 구성하는 것과 유사하지만, 여기서의 대응은 공유된 방정식으로부터 도출되는 것이 아니라 조직적(organizational) 차원의 대응이다.

3.4 유추가 성립하지 않는 지점: 제외되거나 약한 대응관계

본 논문의 핵심적인 방법론적 원칙 — 그리고 이 주제를 다룬 기존의 느슨한 대중적 서술, 즉 본 논문이 대체하는 저자의 초기 비공식 초안과의 의도적인 차별점 — 은 긍정적 사례만큼이나 부정적 사례도 신중하게 보고하는 것이다. 표 4는 검토 과정에서 고려되었으나 정밀검토를 통과하지 못해 표 3에서 명시적으로 제외된 4개의 용어쌍을 나열한다.

용어 A	용어 B	제외 이유
'빔서치(Beam search)' 디코딩	RF '빔포밍(Beamforming)'	'빔(beam)'이라는 단어가 같은 것은 우연이다. 빔서치는 후보 토큰 시퀀스의 탐색 트리를 가지치기하는 것이고, RF 빔포밍은 전자기 에너지를 집중시키기 위해 안테나 배열의 위상을 조향하는 것이다. 공유되는 수학적 도출 과정이 없다.
피드포워드 서브레이어 (토큰별 MLP)	전진오류정정 (FEC)	둘 다 'forward'라는 단어를 포함하지만, 피드포워드 서브레이어는 오류정정 코드 구조가 없는 위치별 비선형 변환일 뿐이다. 둘을 동일시하는 것은 유추를 과장하는 것이다.
레이어/배치 정규화	자동이득제어 (AGC)	둘 다 신호의 통계량을 재조정한다는 점에서 교육적 유추의 동기가 되지만, AGC는 물리적인 진폭/전력 제약을 목표로 하고 정규화는 학습 동역학상의 목표를 갖는다. 총위 3의 발견법으로만 유지하며 그 이상은 주장하지 않는다.
모델의 '확신도' (최대 소프트맥스 확률)	신호대잡음비 (SNR)	소프트맥스 확신도는 잡음 전력 모델로부터 도출된 것이 아니며 Shannon-Hartley 관계를 따르지 않는다. 저자의 초기 비공식 초안이 그러했던 것처럼 둘을 동일시하는 것은 수학적 뒷받침하지 않는 정밀성을 과장하는 것이다.

표 4. 표면적으로는 매력적이지만 대조 분석에서 제외된 용어쌍과 그 구체적인 제외 이유.

IV. 역사적 배경: 두 개의 용어체계가 갈라진 이유

4.1 AI 창설 과정에서 새년이 맡았던 문서상의 역할

III장에서 문서화한 용어적 분리는 우연이 아니며, 추적 가능한 역사를 갖는다. 인공지능이라는 명칭이 부여된 것으로 통상 알려진 1956년 다트머스 여름연구 프로젝트를 소집한 1955년 제안서는 John McCarthy, Marvin Minsky, Nathaniel Rochester, Claude Shannon 네 사람이 공동으로 작성하였다(McCarthy, Minsky, Rochester, & Shannon, 1955/2006). Shannon이 공동 서명자였다는 사실은 해석의 문제가 아니라 문서로 확인되는 역사적 사실이다: 7년 앞서 엔트로피와 채널 용량을 정식화했던 통신공학자가, 이후 관련된 수학에 대해 별도의 용어체계를 발전시킬 분야의 창설 시점부터 자리하고 있었던 것이다. Shannon은 또한 독자적으로 시행착오 학습을 수행하는 전기기계 장치, 특히 '테세우스(Theseus)'라는 이름의 미로 탐색 기계 쥐를 다트머스 회의보다 앞서 제작·시연한 바 있다(Gleick, 2011). 이는 '인공지능'이라는 용어가 존재하기도 전에, 오늘날의 관점에서 기계학습으로 인식될 수 있는 탐색적 작업이 이미 통신공학계에서 진행되고 있었음을 보여준다.

4.2 명칭의 선택: '인공지능' 대 위너의 '사이버네틱스'

AI 역사학자들은, McCarthy가 Norbert Wiener가 1948년부터 이미 사용해오던 '사이버네틱스'라는 용어 — 통신, 제어, 그리고 생물학적·기계적 지능을 하나의 이론으로 통합하려 한 용어(Wiener, 1948) — 를 채택하는 대신 '인공지능'이라는 새로운 이름을 선택한 것이, 부분적으로 Wiener의 연구그룹 및 아날로그 피드백·제어이론 중심의 접근과는 구별되는 독자적인 연구 정체성을 확립하려는 의도에서 비롯되었다고 서술한다(McCorduck, 2004; Nilsson, 2010). 정확한 동기가 무엇이었던, 실질적인 결과는 인접한 수학적 영역에서 작업하던 두 연구공동체 — 하나는 통신·제어공학에서, 다른 하나는 새로 명명된 AI 분야에서 — 가 이후 수십 년에 걸쳐 대체로 분리된 용어체계를 발전시켰다는 것이다.

4.3 AI 겨울과 1986년의 부흥

이러한 분리는 Minsky와 Papert의 1969년 저서 「Perceptrons」가 단층 신경망의 표현력의 한계를 입증한 이후 심화되었다(Minsky & Papert, 1969). 이는 1970년대 신경망 연구에 대한 연구비 지원이 크게 축소된 계기로 널리 인정된다. 1986년 역전파 논문(Rumelhart, Hinton, & Williams, 1986)과 이후 AlexNet과 같은 대규모 이미지 분류 성과(Krizhevsky, Sutskever, & Hinton, 2012)를 계기로 신경망이 부흥하였을 때, 이를 주도한

연구자들은 주로 인지과학과 컴퓨터공학 출신이었고 통신공학 출신은 아니었다. 이에 따라 용어 또한 그 공동체의 관례에 맞추어 새로 만들어지거나 다시 명명되었으며, III장에서 문서화한 여러 사례처럼 수십 년 전 이미 관련 수학을 정식화했던 통신공학 문헌과의 상호 참조는 제한적이었다.

V. 용어체계를 잇기 위한 시각화 프로토타입

어텐션 가중 디코딩과 통신식 신호 선택 사이의 층위 2 대응관계를 일반 대중에게 전달하기 위해, 저자는 단순화된 자기회귀적 디코딩 단계를 애니메이션으로 보여주는 인터랙티브 HTML/JavaScript 프로토타입(가제: pro_briefing_studio.html)을 제작하였다. 이 프로토타입에서는 후보 출력 토큰들의 집합이 수치 점수와 함께 표시되며, 애니메이션이 진행됨에 따라 그럴듯하지 않은 후보의 점수는 감쇄하고 정답 후보의 점수는 임계치를 넘어설 때까지 상승하여 최종적으로 선택된다 — 이는 소프트맥스 출력 분포에 대한 argmax 연산을 대중이 이해하기 쉬운 시각적 형태로 재진술하려는 시도이다. 그림 3은 인쇄를 위해 다시 그린, 동일한 아이디어의 정적 렌더링으로, 질의("한국의 수도는?"), 서로 다른 초기 가중치를 가진 후보 토큰들의 집합, 그리고 가장 높은 점수를 얻은 단일 후보('서울')가 최종 연결을 획득하는 모습을 보여준다.

개념도: 자기회귀적 디코딩에서 후보 토큰들의 경쟁




그림 3. 저자의 인터랙티브 프로토타입(pro_briefing_studio.html)을 바탕으로 재구성한 디코딩 경쟁 시각화의 정적 렌더링. 각 후보 토큰은 모델의 출력 분포에 의해 점수가 부여되며, 가장 높은 점수를 얻은 토큰이 argmax 연산에 의해 선택된다(강조된 단일 연결선으로 표시).

이 프로토타입은 교육 보조자료로 제공되는 것이며, III장의 어떤 수학적 주장에 대한 증거로 제시되는 것이 아니다. 그 목적은 오직 '최고화률 토큰을 선택한다'는 추상적인 개념을, 통신공학 교육에서 회로도나 신호흐름도가 사용되는 것과 같은 정신으로, 처음 접하는 학습자에게 시각적으로 구체화하는 데 있다.

VI. 논의: GoingDeeper NLP 커리큘럼에 대한 합의

6.1 가교 용어집(Bridge Glossary) 제안

표 3은 온보딩 자료로 곧바로 재활용될 수 있다: Seq2seq 노드 시작 시점에 배포되는 한 페이지짜리 '가교 용어집'을 만들어, 새로운 NLP 용어를 층위 1 또는 층위 2에 해당하는 통신공학 대응 개념에 매핑하고, 층위 3 용어쌍은 동일성이 아니라 발견법임을 명시적으로 표시하는 것이다. 이미 통신공학 어휘를 갖춘 학습자에게, 이러한 용어집은 여러 노드 분량의 '새로운 개념 습득'을 '어휘 번역'으로 전환시켜 주며, 이는 훨씬 더 빠른 인지적 작업이다.

6.2 용어적 중복의 비용

본 논문이 우려하는 비용은 GoingDeeper NLP 커리큘럼이 엔트로피, 어텐션, 위치 인코딩을 가르치는 것이 잘못되었다는 것이 아니다 — 이들은 학습자가 정확히 필요로 하는 개념들이다. 문제는 기회비용이다. 통신공학 배경을 가진 학습자가 이미 소유하고 있는 개념을 NLP 전용의 틀로부터 다시 유도하는 데 쓰이는 시간은, 같은 노드에서 진정으로 새로운 내용(예: Transformer의 구체적인 구조적 선택, 혹은 HuggingFace로 파인튜닝하는 실무적 엔지니어링 작업)에 쓰이지 못하는 시간이다. 층위 1과 층위 2의 대응관계를 명시적으로 인정하는 커리큘럼은 이러한 학습자가 그 시간을 중복이 아니라 생산적으로 사용할 수 있게 한다.

6.3 커리큘럼 순서 조정 제안

구체적으로, 본 논문은 GoingDeeper NLP 트랙이 Seq2seq 및 Transformer 노드와 함께 선택적인 '패스트패스(fast-path)' 옵션을 제공할 것을 제안한다. 엔트로피, 채널 용량, 정합필터에 대한 사전 지식을 (예를 들어 표 3을 참조한 간단한 진단 문항을 통해) 입증할 수 있는 학습자는 이론적 배경 절의 축약된 버전으로 안내되고, 절약된 시간을 해당 노드의 구현·평가 요구사항을 확장하는 데 사용하도록 한다. 이는 어떤 학습자에 대해서도 기준을 낮추는 것이 아니라, III장의 대조 분석이 드러내고자 하는 각 학습자의 실제 학습 공백 쪽으로 교육 시간을 재배분하는 것이다.

VII. 한계

본 논문의 대조 분석에는 네 가지 명시적인 한계가 있다. 첫째, 이는 45개 용어로 구성된 작업 목록에 대한 단독 저자의 1회차 분류이며, 표 3의 층위 배정을 검증한 2차 분류자가 없어 상호평가자 신뢰도는 알려져 있지 않다. 둘째, 검토한 1차 문헌 코퍼스는 각 GoingDeeper NLP 노드의 근간이 되는 논문들을 포함하지만 통신공학 또는 딥러닝 문헌 전체를 포괄하지는 않으며, 더 큰 코퍼스는 추가적인 층위 1·2 용어쌍을 드러내거나 일부 층위 3 용어쌍을 재분류할 수도 있다. 셋째, 표 3의 층위 3(개념적) 대응관계와 V장의 시각화 프로토타입은 명시적으로 교육적 장치이다. 이들은 형식적인 수학적 동치성의 증거로 인용되어서는 안 되며, 본 논문은 이 주장의 초기 비공식 버전에서 이루어진 그러한 더 강한 주장들을 명시적으로 철회한다. 넷째, 본 논문은 GoingDeeper CV 트랙, 강화학습, 생성적 적대 신경망(GAN)을 분석하지 않는다. 이러한 영역에서도 유사한 통신공학적 대응관계가 존재하는지는 후속 연구로 남긴다.

VIII. 결론

본 논문은 AIFEL GoingDeeper NLP 커리큘럼이 고전적인 정보·통신이론에서 이미 정립된 수학을 새로운 이름 아래 다시 가르친다는, 통신공학자로서의 의구심을 단순히 주장하는 것이 아니라 검증하고자 하였다. 그 답은 조건부로 성립한다. 한 가지 대응관계 — 새넌 엔트로피와 크로스엔트로피 손실함수 — 는 단순한 시사(suggestive)가 아니라 정확하고 증명 가능하다(2.3절). 어텐션-상관관계 대응과 사인파 위치 인코딩의 푸리에 기저 대응을 포함한 추가 7개의 용어쌍은 인용된 문헌에서 구체적인 수학적 도출로 뒷받침된다(3.2절, 층위 2). 세 번째 그룹의 용어쌍은 직관을 가르치는 데는 참으로 유용하지만 동일성으로 오해되어서는 안 되며, 'beam search'와 'beamforming' 사이의 우연한 유사성을 포함한 네 번째 그룹은 오도하는 유추로서 적극적으로 지양되어야 한다(3.4절). 역사적으로 이 분리는 문서로 확인되는 구체적인 순간으로 소급된다: Claude Shannon은 AI라는 분야를 명명한 1955년 다트머스 제안서에 공동 서명하였고, 이후 수십 년에 걸쳐 그 분야의 용어체계는 그럼에도 그의 것으로부터 갈라져 나갔다(IV장). 이로부터 도출되는 실천적 제안은 소박하지만 실행 가능하다: 간단한 가교 용어집(표 3)과 선택적인 패스트패스 순서 조정(6.3절)은, 통신공학 배경을 가진 학습자가 한정된 학습 시간을, 이미 알고 있는 것을 낯선 이름으로 다시 배우는 데가 아니라 GoingDeeper NLP 커리큘럼에서 진정으로 새로운 내용에 쓸 수 있게 할 것이다.

참고문헌

- Cover, T. M., & Thomas, J. A. (2006). Elements of Information Theory (2nd ed.). Wiley.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT 2019, 4171-4186.
- Gleick, J. (2011). The Information: A History, a Theory, a Flood. Pantheon Books.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of CVPR 2016, 770-778.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25.
- McCarthy, J., Minsky, M. L., Rochester, N., & Shannon, C. E. (1955/2006). A proposal for the Dartmouth Summer Research Project on Artificial Intelligence. AI Magazine, 27(4), 12-14.
- McCorduck, P. (2004). Machines Who Think (2nd ed.). A K Peters/CRC Press.
- Minsky, M., & Papert, S. (1969). Perceptrons: An Introduction to Computational Geometry. MIT Press.
- Nilsson, N. J. (2010). The Quest for Artificial Intelligence: A History of Ideas and Achievements. Cambridge University Press.
- Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. Nature, 323(6088), 533-536.
- Shannon, C. E. (1948). A mathematical theory of communication. Bell System Technical Journal, 27(3), 379-423.
- Shannon, C. E., & Weaver, W. (1949). The Mathematical Theory of Communication. University of Illinois Press.
- Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. Advances in Neural Information Processing Systems, 27.
- Tsai, Y.-H. H., Bai, S., Yamada, M., Morency, L.-P., & Salakhutdinov, R. (2019). Transformer dissection: An unified understanding for transformer's attention via the lens of kernel. Proceedings of EMNLP-IJCNLP 2019, 4344-4353.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

Wager, S., Wang, S., & Liang, P. (2013). Dropout training as adaptive regularization. *Advances in Neural Information Processing Systems*, 26.

Wiener, N. (1948). *Cybernetics: Or Control and Communication in the Animal and the Machine*. MIT Press.

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., et al. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of EMNLP 2020: System Demonstrations*, 38-45.

감사의 글: 저자는 본 연구의 분석 및 집필 단계에서 Claude(Anthropic)를 AI 연구·집필 보조도구로 사용하였다 — 용어 대조 검토의 구성, 그림 1~3의 생성, 원고 교정을 포함한다. 표 4의 항목을 제외하기로 한 결정을 비롯한 모든 분류·논증·결론은 저자 본인의 것이다.